北京大学
PEKING UNIVERSITY

MemoryFlow

Agent 任务中细粒度信息的来源与流动

宋政兴

2026 / 10 / 29

汇报内容

北京大学 PEKING UNIVERSITY

01 研究背景

RAG 溯源的已有基础，Agent 场景的适配问题

02 研究问题与方法

多证据长输出的回放分析，跨调用的信息追踪

03 初步实验与案例

来源质量、前缀复用效率、DCC 判断链

04 当前进展

原型衔接与原生 SP2 场景验证

研究背景：DCC 判断需要完整的依据链

场景：Agent 阅读规则与业务材料，给出合规判断

最终输出
“该操作符合要求”

依据是什么？

对应哪条规则，使用了哪些事实

条件检查了吗？

适用条件、限制和例外是否都被考虑

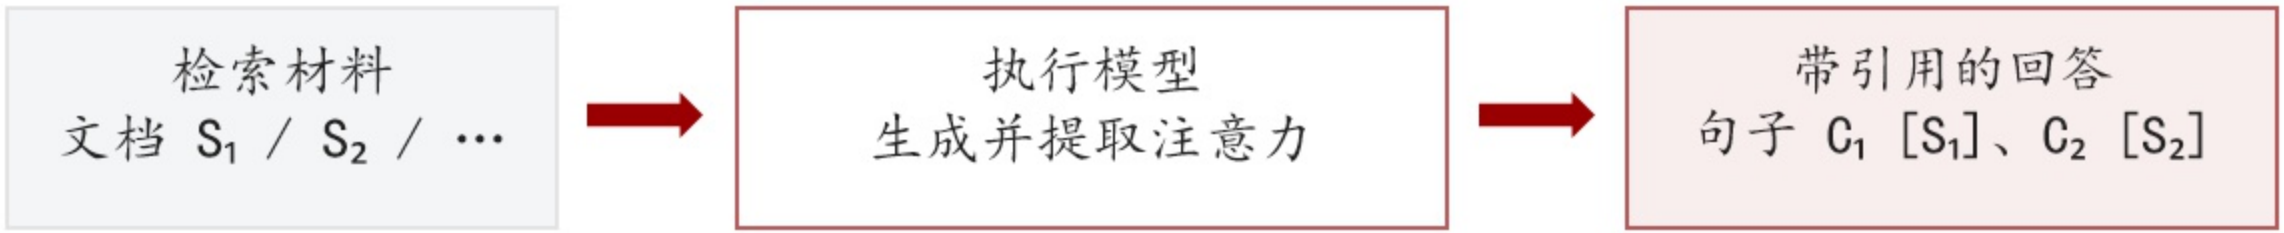
判断怎样形成？

经过了哪些摘要、核查和转述

需要记录判断的形成过程，支持审阅、复核与问题分析

已有基础：yf 在 RAG 中有效的引用溯源

在同一次问答中，将生成内容对应到检索材料



有效的来源信号

发现并读取具有引用能力的**注意力头**，
把输出子句的分数汇总到**来源句子**

已有**生成时实现与问答部署**，给我们提供了可借鉴的注意力信号

进一步的问题：Agent 已经完成的多阶段判断，怎样接上这套能力？

适配问题：Agent 改变了溯源的任务条件

变化	Agent 场景里发生什么	需要增加的能力
记忆转化	原文先压缩成摘要，再参与后续判断	跨调用追踪，保留中间变换
长任务与多指令	规则、工具、规划和历史混在输入里，输出也更长	固定目标分析，控制长上下文开销
执行模型与接口	不同 Agent 可用不同模型，API 通常不返回注意力	独立回放，接入已有运行记录

场景变化使 RAG 中的直接使用方式需要适配：
既要能分析**已有文本**，也要能**连接不同阶段**

这是任务条件与接口的差异。Agent 上的适配效果由后续实验分别验证。

具体缺口：最终引用还需要连接中间判断

NBA 旧受控案例中的实际内容变化

题面事实	中间核查	最终判断
2020 年签了四年合同	→ “completed 4 years of service”	→ 沿用“少于七年服役”并判合规

审阅者需要定位的两个层次

原始材料层：这次判断引用了哪些规则和事实？

加工过程层：“合同期限”在**哪一步**被写成“服役年数”？

Qwen2.5-7B 三阶段受控样例。第二步有输出上限，原生 SP2 案例正在补充。

统一研究问题：细粒度信息怎样传到结果

基本单位：具体条款、事实与判断片段

用途	沿链路追查什么	对应的细粒度内容
DCC 核查（重点）	判断依据与核查过程是否可查	条款条件、适用事实、逐项判断
引用溯源（重点）	输出经过哪些处理，来自哪些材料	原文片段、摘要子句、输出陈述
错误分析（延伸）	可疑说法的出现和沿用位置	出错的说法、相关步骤与 Agent

维护从证据到判断的信息链路，才能逐项检查条件与内容变化

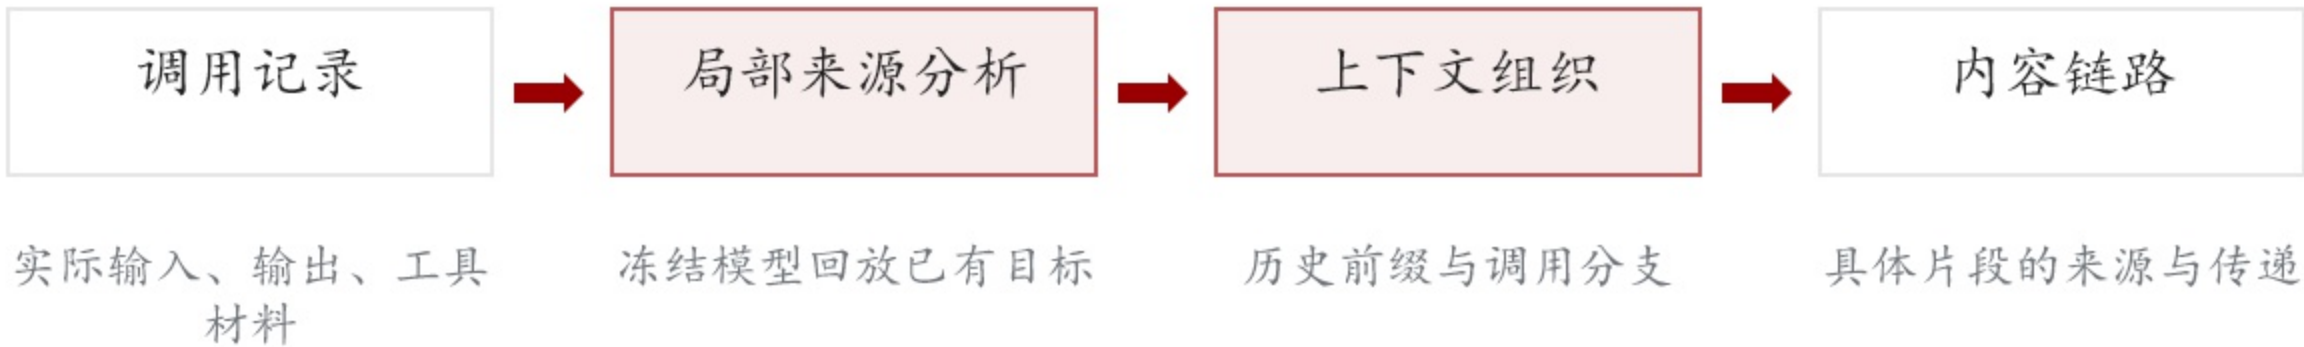
两个核心挑战与对应设计

研究挑战	需要回答	方法设计
多证据、长输出 高效后处理	给定已有输出，如何准确且高效地找到来源？	目标回放 + 固定头读出 共享前缀减少重复计算
多轮调用中的记忆转化	不同调用看到不同材料，局部关系如何接起来？	按调用构造局部矩阵 在轨迹森林上对应内容

两个部分共同服务于信息链路

先建立一次调用内部的对应，再沿**实际传入的内容**连接多次调用

方法总览：局部回放与全局信息流



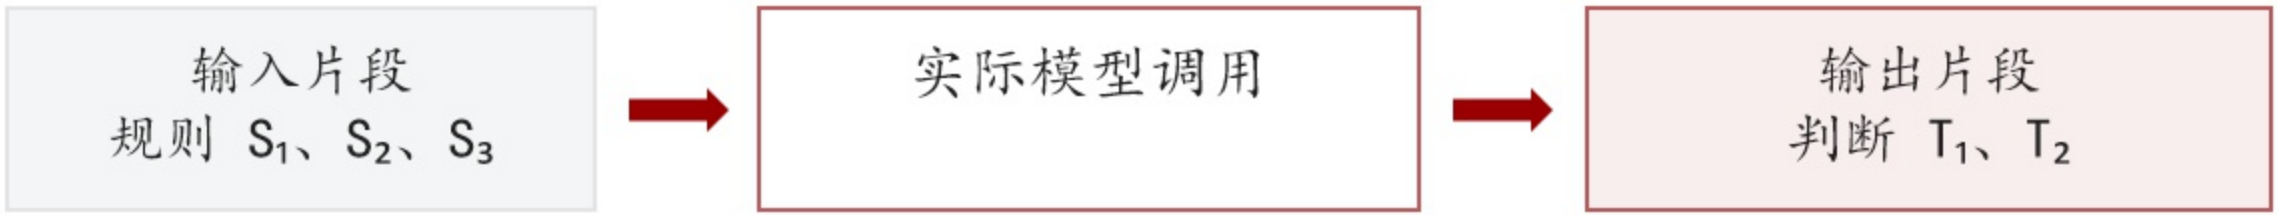
输入是什么？ 已有的执行轨迹与目标文本

输出是什么？ 可查阅的**局部矩阵**与跨调用**内容链**

局部分析已有实现，跨调用已有小型案例；通用组织与连接规则继续完善。

基本建模：一次调用对应一张局部矩阵

TITO：以一次模型调用的输入和输出为基本记录



输出 × 输入	规则 S_1	规则 S_2	规则 S_3
判断 T_1	0.4317	0.0783	0.0147
判断 T_2	0.0647	0.3289	0.0693

行表示**输出单元**，列表示**可见来源**；每格记录一个回放来源分数

一张调用矩阵可由多次前向得到，矩阵数量不等于前向次数

NBA 样例 check_2 / check_3 对 rule_12 / rule_15 / rule_16 的分数，表中仅列部分来源。

方法一：用固定回放模型分析已有输出

保留注意力来源信号，将分析对象固定为已有文本

来源上下文 P
固定提示 + 候选材料

已有目标 T
本次需要解释的陈述



冻结的 Qwen2.5-7B-Instruct

① 沿**预测目标词的位置**，读取固定头的注意力

② 对目标位置**取平均**，对候选来源区间**求和**，得到每个来源的分数

当前使用第 20 层第 16 个头，零基 (19,15)。固定模型与读出规则，不重新生成目标。

读出与 Mask：已有词如何并行处理

教学示意：T = “我 喜欢 吃 苹果”，所有目标词已给定

计算位置	前缀末位	“我”的位置	“喜欢”的位置	“吃”的位置
对应预测词	我	喜欢	吃	苹果

实际评分输入：P +“我 喜欢 吃”，在“吃”的位置分析接下来的“苹果”

保持因果可见性

每个位置读取来源前缀与**之前的目标词**，
未来词由因果 Mask 屏蔽

不同目标分别处理，**缓存复位**保证分支隔离；**目标内部成块**计算

当前实测使用依次处理的分支；多个分支一次前向打包仍属后续实现。

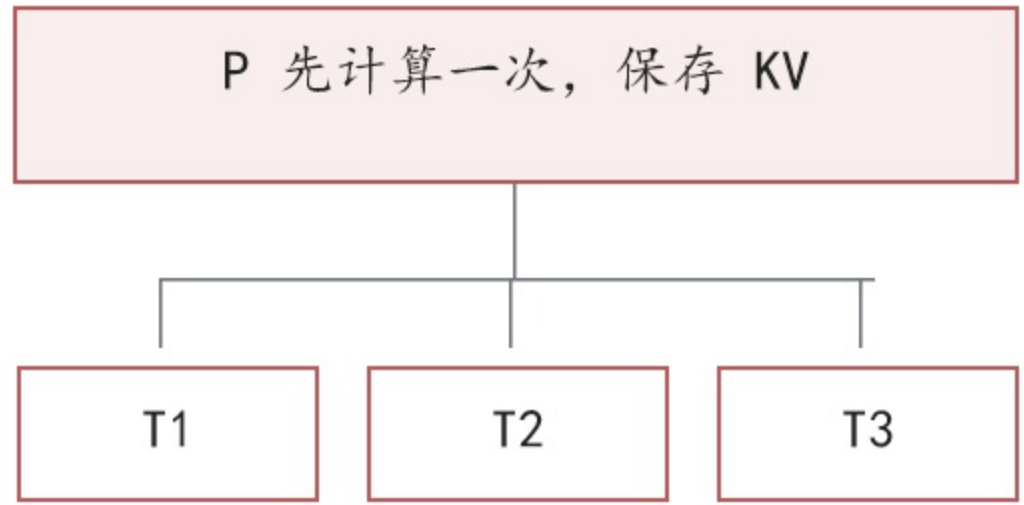
效率设计：复用共同前缀，保留独立目标

重复计算：每个目标都读一遍长来源



每个目标：长前缀 + 短目标

当前实现：同组前缀只读一次

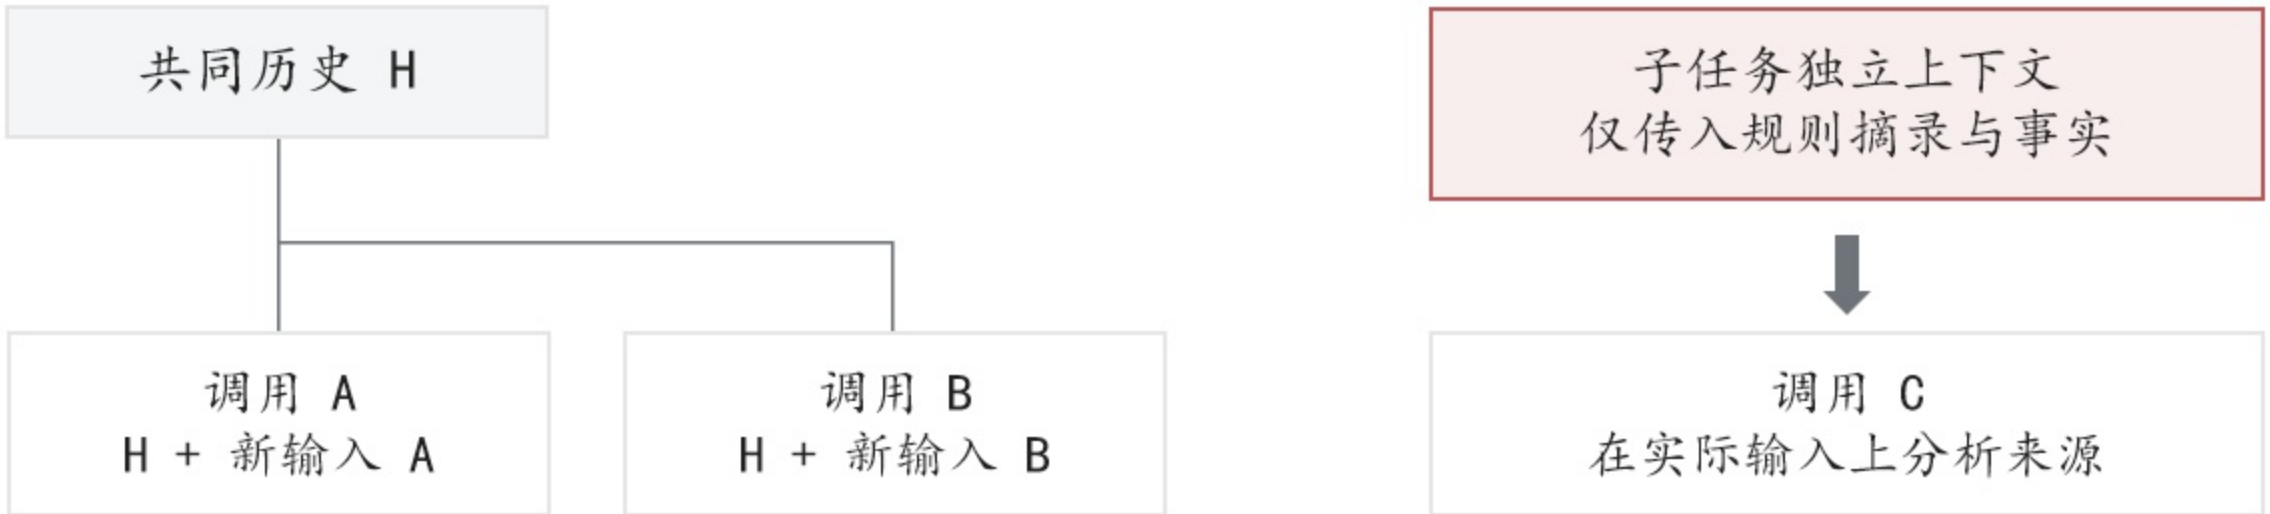


先复用 P，再依次处理各目标并复位

目标不同仍需各自分析，共同前缀的计算可以复用

方法二：轨迹森林先还原可见上下文

为什么需要结构？整个运行里出现过，不等于这次调用看得到



森林记录调用看到了什么，局部矩阵在可见内容中找来源

多轮连接：沿实际传入的内容接上局部矩阵

CUAD 已有样例：原文片段、研究摘要、最终结论

合同 §2.1 “preemptive right” → 研究摘要 定位到 §2.1 优先权 → 最终输出 逐字摘录 §2.1 条款

已核对的摘要内容进入后续请求，按记录包含关系对齐

局部矩阵 M_1	答案片段	其他来源
研究摘要	0.7595	…

局部矩阵 M_2	研究摘要	可见原文
最终结论	0.6437	0.3563

研究者读到全部 13 个片段；报告者**只收到摘要**与其中 1 个片段

沿摘要的实际传递，将“结论与摘要”和“摘要与原文”接成两跳

中间 repair 输出全文未留存。表中为候选间来源分数，M_1 仅列部分来源。

实验设计：分别验证来源、效率与链路

需要回答	已有实验	观察什么
来源是否找得准？	GenMem 多轨迹来源排序	能否找齐完整证据；与强基线比较
计算是否更省？	同一批目标，重复前缀与共享前缀对照	分数一致性、耗时和显存
Flow 是否有用？	CUAD 两跳与 NBA 中间判断案例	能否追到原文与中间内容变化

GenMem 评价范围

10 条轨迹收集 100 个目标，当前有效评价 55 个
主评测为 8 条轨迹的 47 个目标，另有 8 个开发目标

来源质量：前十候选找齐完整证据

主指标：组内片段共同支持（AND），多套可接受解释任选一套（OR）

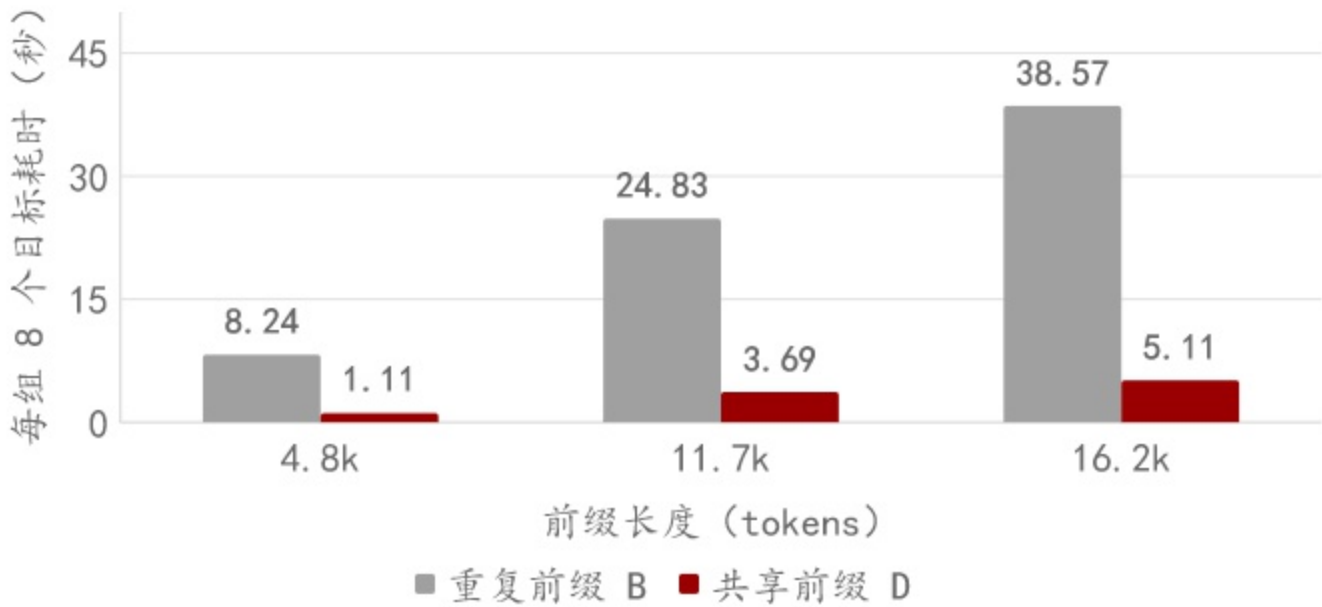
方法	完整证据 @5	完整证据 @10
固定头回放（当前配置）	59.57%	70.21%
D-Full（3 seed 均值）	53.19%	68.09%
BM25	55.32%	61.70%
最后八层全头平均	57.45%	61.70%

当前固定头相对 BM25 在 @10 净多找齐 **4 个目标**

与 D-Full 的**差距较小**，后续重点验证独立任务上的稳定性

N=47。抽样头 L21H5 的 @10 为 76.60%；BM25 首位片段命中更高。完整结果见备份。

效率验证：主要收益来自前缀复用



6.7–7.6×

B → D 的整组加速

同一计算路径
来源分数**逐项一致**
峰值显存**基本相同**

已测 3 组 × 8 个目标；整批收益还取决于前缀可共享比例

DCC 案例：由最终判断定位到具体核查

NBA comp_0#003，Qwen2.5-7B 受控样例

规则与事实
<7 年顶薪档规则
2020 年四年合同

→

check_2
“4 years of service”
据此套用 25% 档

→

最终判断
沿用该档位与年数
输出合规结论

局部回放：check_2 对该规则分数 0.4317；最终判断对 check_2 为 0.8047

原文核查：“四年合同”被转成了“服役四年”，并在后续判断中沿用

展示价值：从粗粒度执行步骤，进一步定位到条款、事实与具体说法

分数为候选间的回放关联，辅助人工检查。第二步有输出上限，原生 SP2 案例待返回。

当前进展与后续重点

模块	当前进展	下一步
局部来源分析	回放、局部矩阵与多基线比较已完成	独立任务与不同来源类型验证
计算优化	共享前缀复用已有一致性和计时结果	补整批端到端测量
跨调用信息流	已有 CUAD 两跳和 NBA 小型案例	统一输入、内容位置、矩阵及连接
DCC 展示	原生 SP2 的 DCCv2 接入任务已派发	运行 NBA 案例 形成可查阅的依据链

近期交付：把已有模块接成最小原型，补齐真实 DCC 场景展示

Q&A

敬请老师批评指正

MemoryFlow

备份：旧 Anchor 与回放路径的差异

处理路径	读出方式	首位命中
旧 Anchor	最后八层平均	37.50%
旧 Anchor	固定头（19, 15）	25.00%
回放	最后八层平均	81.25%
回放	**固定头（19, 15）**	**90.63%**

整条表示与读出路径发生变化，单独换头不足以解释改善

32 个短样本诊断，与 GenMem 主表属于不同数据和协议。

备份：A / B / C / D 的计算安排

实现	目标 token	公共前缀	目标之间
A	逐个回放	每目标重算	依次处理
B	成块计算	每目标重算	依次处理
C	成块计算	每目标留一份	普通 batch
D（当前）	**成块计算**	**同组只算一次**	**依次处理分支**

B 与 D：24 个目标、10,984 个候选，逐项分数**差异为 0**

A 与 D：Top-1 全同，Top-5 集合有 4 / 24 因数值换位

D 的收益来自前缀复用；多目标一次前向的分支 packing 仍待实现。

备份：完整主表与注意力头消融

方法	完整组 @5	完整组 @10	首位片段命中
固定头回放	59.57%	70.21%	48.94%
D-Full（3 seed）	53.19%	68.09%	34.04%
BM25	55.32%	61.70%	57.45%
平均头	57.45%	61.70%	34.04%
R-SYM（3 seed）	44.68%	58.16%	39.01%
Qwen 表示相似度	27.66%	40.43%	19.15%
CLM 官方头迁移	12.77%	19.15%	12.77%
均匀随机排序	1.08%	2.15%	0.44%

抽样头 L21H5：完整组 @5 为 55.32%，@10 为 76.60%

N=47；CLM 为已训练官方头直接迁移。D-Full 新旧差异涉及评价分母。

备份：yf 的部署效率与比较范围

作者已经提供 CUDA Graph 兼容的注意力提取

作者汇报中的设置	单并发吞吐	四并发总吞吐
默认 CUDA Graph	30.02	88.92
PIECEWISE，无 hook	29.70	88.01
PIECEWISE，有 hook	**29.71**	**87.09**

生成时路线：测量执行模型**增加溯源后的开销**

MemoryFlow：测量已有轨迹的**回放成本**与**前缀复用收益**

来自 yf 10/24 汇报第 4 页。该页未注明吞吐单位；两条路线需同环境分别计时。