北京大学
PEKING UNIVERSITY

MemoryFlow

Agent 任务中细粒度信息的来源与流动

宋政兴

2026 / 10 / 29

汇报内容

北京大学 PEKING UNIVERSITY

01 研究背景与问题

为什么已有引用还需要扩展到跨调用信息流

02 方法机制

一段原文怎样变成矩阵中的一格，再接成路径

03 初步结果与案例

来源评价、复用效率与具体内容变化

04 当前进展与缺口

已有实现、总体设计与待补实验

实际需求：合同判断的依据怎样查

DCC：文档与规则的合规核查，要求判断依据可复核

待核查问题
合同中是否存在
优先权类条款？

→

系统给出的原文摘录
“Party A shall have a preemptive right …”

审阅者继续追问：对应**哪一段原文**？**中间摘要**怎样解释它？

若解释被压缩、改写或遗漏，问题最早出现在**哪一步**？

需要同时记录原始依据与判断形成过程

CUAD 已有样例，问题为类别转述；“preemptive right”是否属于该类仍需专业审核。

已有思路：生成时引用与跨调用追踪

已有生成时溯源

检索材料 → 生成回答并提取引用 → 带引用的答案

RAG 中已有有效的**注意力引用信号**，可把回答对应到检索材料

Agent 增加了新的分析要求

原文先变成**摘要**，再被后续调用使用；分析对象是整条**已完成轨迹**

保留已有来源信号，补上独立回放与跨调用连接

适配问题：材料会变，调用看到的内容也会变

Agent 场景的变化	带来的问题	对应需求
摘要、改写与传递	最终输出可能只看到中间摘要	保留加工过程，跨调用回查
长输入与多个输出	相同长材料会被多次重复处理	固定目标评分，复用相同计算
执行模型与 API 各异	执行模型的内部注意力未必可提取	来源分析与任务执行解耦

直接沿用**一次问答**的引用接口，难以覆盖这**三类要求**

研究对象扩展为：已有轨迹中的细粒度信息流

统一目标：以具体内容为单位回查判断

追踪对象是条款、事实与判断片段

应用	回查的内容	希望帮助谁做什么
DCC 核查（重点）	条款条件、事实、中间核查	审阅者逐项检查判断依据
引用溯源（重点）	原文、摘要子句、最终陈述	使用者查到文字的原始出处
错误分析（延伸）	可疑说法及其后续沿用	分析者定位值得核查的环节

同一条内容路径，可以用于依据审阅、引用追查与问题定位

两个挑战：先建立局部关系，再连接多轮

挑战	具体问题	设计
一次调用内部	每段输出与哪些可见输入有关？ 长材料怎样避免重复计算？	已有目标回放 局部来源矩阵 + 前缀复用
多次调用之间	上一次输出进入了哪次输入？ 内容转化后怎样继续追查？	记录可见上下文 对应中间内容并连接路径

接下来沿一份合同的“**原文—研究摘要—最终摘录**”解释这两部分

方法流程：每一步保存什么



实际输入输出
候选区间、目标单元

目标逐一评分
保存来源矩阵

前次输出与
后次输入的位置

最终输出、中间内容
原始材料及记录

产物　　带**调用身份**、**原文位置**和**来源分数**的可查阅链路

局部评分与固定案例路径已有产物；通用森林组织和连接规则仍在完善。

步骤一：先确定可见材料和待解释的输出

真实 CUAD 案例

本次实际输入	本次已有输出
候选 S_1：含合同 §2.1 的检索片段 “Party A shall have a preemptive right …”	目标 U：研究者返回的摘要 “Section 2.1 … preemptive right …”
候选 S_2、S_3…：其他检索片段	保留原摘要全文作为评分目标

每个候选保留字符 / token **区间**，每个目标保留**所属调用**与输出位置

当前案例候选为检索窗口；摘要整体为一个目标。统一的更细粒度切分仍待确定。

步骤二：冻结模型回放，目标文本已经给定

执行模型负责产出，回放模型负责分析这份已有产出

来源上下文 P
实际请求中的候选与其他上下文

目标 U
已经保存的研究摘要



Qwen2.5-7B-Instruct　冻结参数

得到的是：**目标各预测位置**，对**来源 token** 的注意力

GenMem 使用固定候选排序模板；真实调用案例使用保存的请求文本。

步骤三：词级注意力怎样汇总成一个分数

计算示意，非实验数值

目标的预测位置	来源 S_1 的区间总量	来源 S_2 的区间总量
位置 j_1	0.30	0.10
位置 j_2	0.20	0.20
沿目标位置取平均	0.25	0.15
在所选来源间归一化	0.625	0.375

每个位置先把**同一来源区间**内的 token 权重相加，再**沿目标位置平均**

一格分数回答：在给定候选中，这个目标与该来源的关联有多强

其他上下文权重未列。候选归一化分数用于排序，不能解释为正确率或因果贡献。

步骤四：把每段输出的来源分数排成矩阵

一行对应一个输出单元，一列对应一个可见来源

输出 × 输入	来源 S_1	来源 S_2	其他来源
研究摘要 U	一组候选分数	一组候选分数	…
另一输出单元 T	单独回放得到	单独回放得到	…

同一次调用的多个输出单元：**分别评分**，再按**相同候选列**堆成多行

一次真实调用是一条记录；评分器可以用多次前向构造这张矩阵

NBA 案例按编号拆出 6 个 check；当前逐个回放，不等同于对完整输出一次前向切行。

计算组织：已知目标与因果可见性

文本已经给定，各位置可以成块计算

给定目标 token	a	b	c
实际读出位置	前缀 P 的末位	a 的位置	b 的位置
该位置分析的目标	**a**	**b**	**c**

每个位置只看来源前缀和**之前的目标词**，**未来词**由因果 Mask 屏蔽

不同目标使用**独立分支**；当前通过依次处理与**缓存复位**保持隔离

a、b、c 表示示意 token，实际分词由 Qwen tokenizer 决定。

计算复用：相同长前缀只处理一次

重复前缀

相同来源上下文 P	T1
相同来源上下文 P	T2
相同来源上下文 P	T3

共享前缀，目标分别处理



前缀看不到后面的目标，因此相同前缀的计算结果可以复用

仅对 token、位置及 Mask 设置相同的前缀分组复用；目标仍逐个分析。

跨调用问题：下一次未必还能看到全部原文

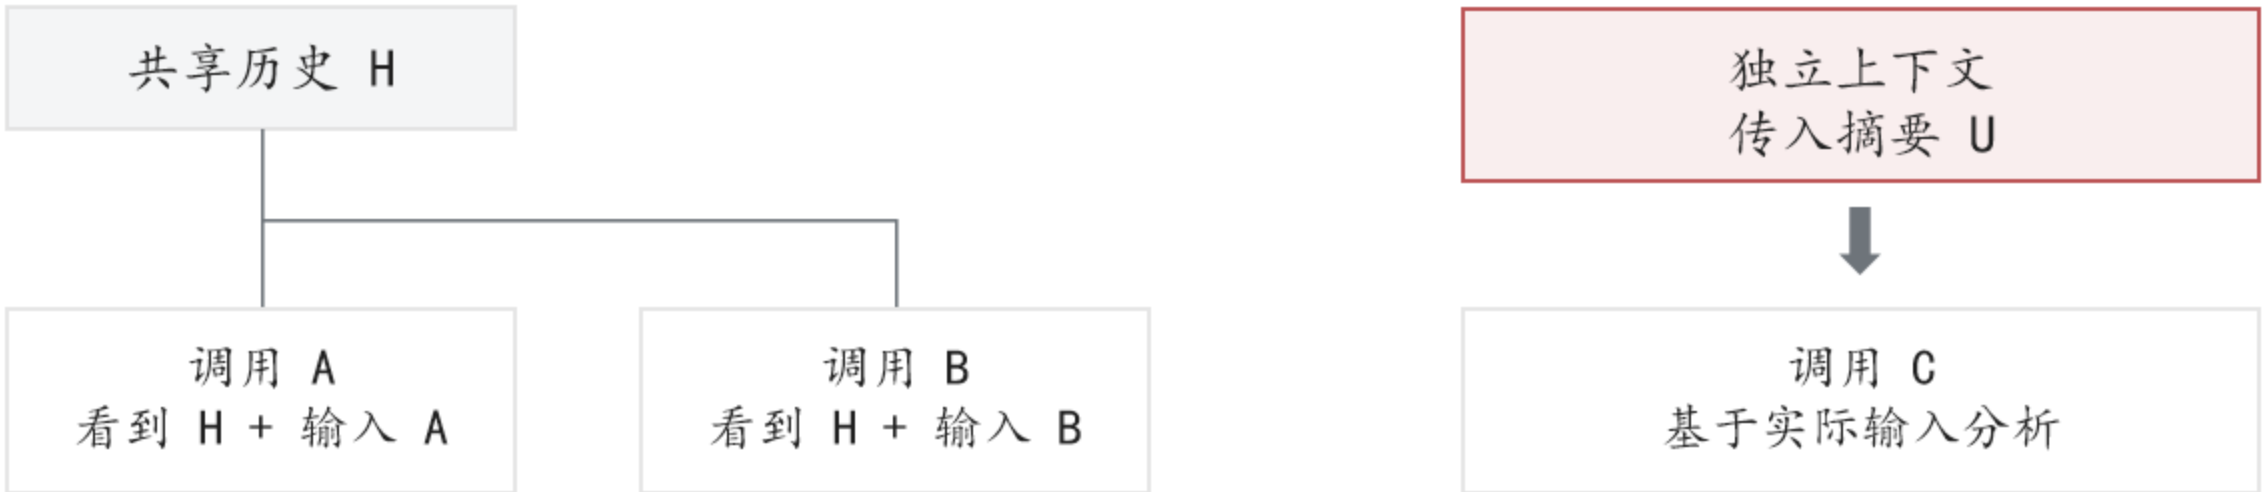
真实 CUAD 请求记录

研究者调用	报告者调用
实际输入：13 个合同片段 包含 §2.1 的候选与其他候选	实际输入：研究摘要 U 以及含 §2.1 的 1 个原文片段
实际输出：研究摘要 U	实际输出：最终摘录 V

其余 12 个原文片段**没有直接进入**报告者请求，回查时需经过中间内容

记录中存在 repair 环节，完整输出缺失；当前按已保存的摘要包含关系核对。

轨迹森林：组织上下文，信息流叠加其上



上下文结构：共享历史与调用分支

内容关系：具体片段之间的来源关联与实际传递

现有案例按调用记录连接，尚未接入通用前缀森林构建。叠加内容关系后形成信息流图。

连接关键：前次输出成为后次输入中的同一内容

先核对内容对应，再接来源关联

研究者输出
摘要 U
“… Section 2.1 … preemptive right …”



报告者实际输入
来源项 U
“… Section 2.1 … preemptive right …”

内容对应：U 的**身份、文本与出现位置**由调用记录核对

来源关联：M_1 连接“摘要 U—原文”，M_2 连接“结果 V—摘要 U”

连接点是实际传入的内容，不依靠两张矩阵的相似度猜测

图中文字为摘要节选；该例中间 repair 全文缺失，按记录包含关系核对。

回查结果：最终摘录经过了哪些可见路径

路径示意，关联分数暂不展示



回查路线：从 V 找到输入中的 U，再从 U 回到含 §2.1 的候选原文

本例还存在 S 直接进入报告者请求的路径，应与间接路径同时保留

只沿实际可见路径回查。现有最大乘积聚合是案例实现，通用聚合规则待定。

评价问题：前几个候选能否给出完整解释

GenMem 多来源标注例子

目标：Secret Symphony 是 Katie Melua 的第五张录音室专辑，
并由 Mike Batt 参与制作

证据 A
“Secret Symphony is the fifth studio album …”

证据 B
“produced in collaboration … Mike Batt”

A 与 B 需要**共同支持**（AND）；若存在另一套**完整解释**，可任选一套（OR）

CompleteGroup@K：前 K 个候选中，是否找齐任意一套完整证据

contextual64_v4, genmem_874c34ceb20bf193:selected_03：展示目标与证据的节选 / 转述。

来源质量：已有多方法结果与待补核项

历史冻结结果，待版本补核

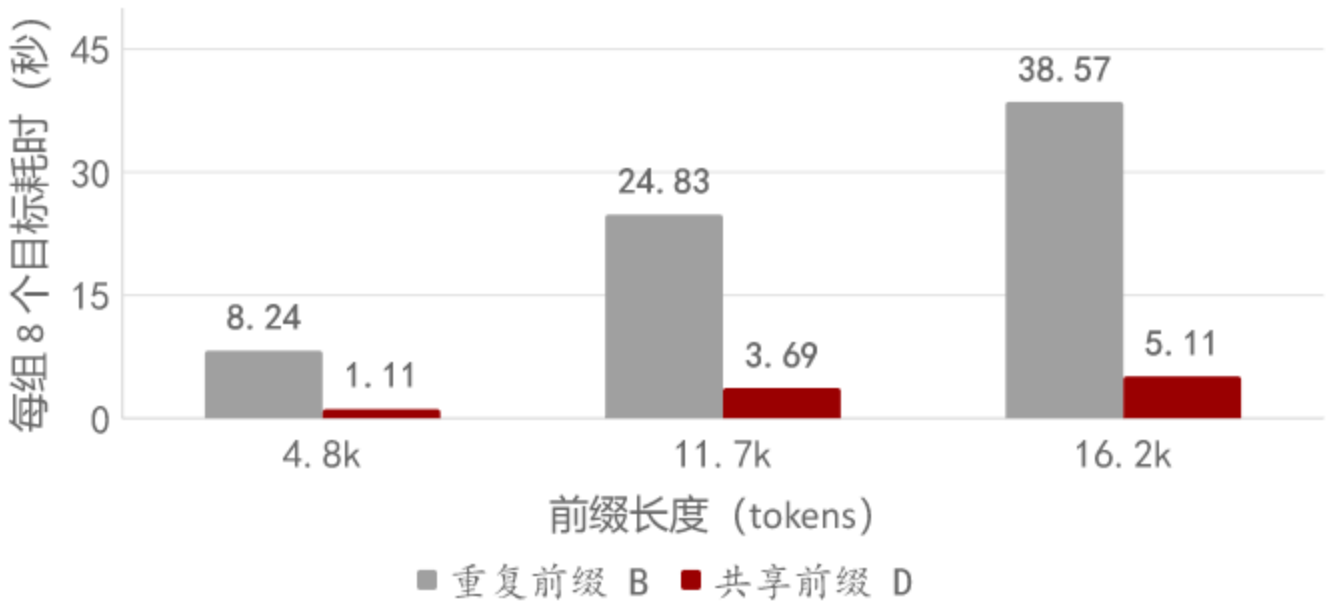
方法	完整组 @5	完整组 @10
固定头回放（现有记录）	59.57%	70.21%
D-Full（3 seed 均值）	53.19%	68.09%
BM25	55.32%	61.70%
最后八层全头平均	57.45%	61.70%

主评测：8 条轨迹、**47 个目标**；另有 8 个开发目标

当前需先核对评分模块的**历史版本**与**候选区间边界**，再更新质量结论

抽样头 L21H5 的 @10 为 76.60%，未据评测换头；各方法仍按原报告保留。

效率验证：共享前缀减少了多少重复计算



6.7 – 7.6×

B → D 的整组加速

同一计算路径
来源分数**逐项一致**
峰值显存**基本相同**

已测 3 组 × 8 个目标；整批可共享比例与端到端耗时正在补测

另一类 DCC 发现：具体说法在哪一步变化

NBA 已有三阶段受控样例

题面事实	中间核查	最终判断
2020 年签订四年合同	“completed 4 years of service”	沿用“少于七年服役”并判合规

可核查的变化：“**合同期限**”被转成了“**服役年数**”，后续又沿用了它

信息链路帮助定位值得检查的说法，正确性仍要回到规则和事实

Qwen2.5-7B 旧受控样例，第二步触及输出上限；原生 SP2 完整案例待返回。

当前完成范围与真正缺口

部分	已具备	仍需补齐
局部分析	回放、候选位置与逐目标评分产物	区间边界核对，切分与输出前文协议
跨调用案例	选定调用的内容对应与两跳路径	稳定内容 ID、通用森林、路径查询
实验证据	多方法历史结果、独立复用计时	原生 SP2 案例、整批成本与多跳价值

近期先完成：**评分补核**、**完整案例记录**、最小可查阅 **Flow 原型**

已派发的 DCCv2 NBA 与效率补测仍在执行，返回后更新对应页面。

Q&A

敬请老师批评指正

MemoryFlow

备份：旧 Anchor 与回放路径的差异

处理路径	读出方式	首位命中
旧 Anchor	最后八层平均	37.50%
旧 Anchor	固定头（19, 15）	25.00%
回放	最后八层平均	81.25%
回放	**固定头（19, 15）**	**90.63%**

整条表示与读出路径发生变化，单独换头不足以解释改善

32 个短样本诊断，与 GenMem 主表属于不同数据和协议。

备份：A / B / C / D 的计算安排

实现	目标 token	公共前缀	目标之间
A	逐个回放	每目标重算	依次处理
B	成块计算	每目标重算	依次处理
C	成块计算	每目标留一份	普通 batch
D（当前）	**成块计算**	**同组只算一次**	**依次处理分支**

B 与 D：24 个目标、10,984 个候选，逐项分数**差异为 0**

A 与 D：Top-1 全同，Top-5 集合有 4 / 24 因数值换位

D 的主要收益来自前缀复用；多目标一次前向的分支 packing 仍待实现。

备份：历史主表与注意力头消融

冻结记录，评分版本待补核

方法	完整组 @5	完整组 @10	首位片段命中
固定头回放	59.57%	70.21%	48.94%
D-Full（3 seed）	53.19%	68.09%	34.04%
BM25	55.32%	61.70%	57.45%
平均头	57.45%	61.70%	34.04%
R-SYM（3 seed）	44.68%	58.16%	39.01%
Qwen 表示相似度	27.66%	40.43%	19.15%
CLM 官方头迁移	12.77%	19.15%	12.77%
均匀随机排序	1.08%	2.15%	0.44%

抽样头 L21H5：完整组 @5 为 55.32%，@10 为 76.60%

N=47。原报告保留，补核后按受影响范围更新，不能将现记录当作最终结论。

备份：通用方法需要明确的几项选择

问题	现有案例做法	通用方法待确定
目标前文	每个 check 独立回放	是否保留该输出之前的全部内容
内容粒度	检索窗口、摘要整体、编号判断	条件级或句子级的统一切分
重复出现	分别定位，再按来源取最大	重复项如何合并与解释
跨跳聚合	合法路径乘积，再取最大值	聚合规则与多来源联合条件
内容连接	已知单元与请求内文本对应	沿用、复制、改写分别如何记录

这些选择需要**协议与实现说明**，单靠补跑一个案例无法替代

备份：生成时提取与独立回放的成本

已有生成时提取可以兼容 CUDA Graph

已有部署报告的设置	单并发吞吐	四并发总吞吐
默认 CUDA Graph	30.02	88.92
PIECEWISE，无 hook	29.70	88.01
PIECEWISE，有 hook	**29.71**	**87.09**

生成时路线：利用执行模型已有计算，测**额外提取开销**

独立回放路线：分析已有轨迹，测**回放成本**与**前缀复用收益**

10/24 部署汇报第 4 页。吞吐单位未明确标注，横向比较需统一模型与计时条件。