MemoryFlow

Agent 任务中细粒度信息的来源与流动

研究进展汇报

宋政兴

2026 年 11 月

汇报内容

北京大学 PEKING UNIVERSITY

01 研究背景与问题

一个合同样例：原文、研究摘要和最终摘录

02 MemoryFlow 方法

一次调用的来源矩阵，以及跨调用的内容连接

03 实验、案例与下一步

来源质量、计算效率、链路查询及正式场景验证

研究背景：文档核查中的依据审阅

DCC：Agent 完成核查后，人还需要审阅判断依据

典型工作

读取文档与规则
核查相关事实和条件
给出引用、理由或判断

审阅者需要继续核对

依据来自**哪段材料**？
解释在**哪个中间环节**产生？

已有样例：CUAD 优先权类条款定位

任务：找出与 ROFR / ROFO / ROFN 类别相关的合同条款（转述）

实际返回的合同原句

2.1 Party A shall have a **preemptive right** to carry out mobile game services with Party B on a nationwide basis.

原文写了“优先权”，类别关系需要进一步解释

已有 CUAD 机制样例；此处只说明依据审阅需求，不判定条款的法律类别。

真实案例：条款在中间摘要中得到解释

研究摘要增加了解释与保留意见，最终报告回填原句

合同原文 · §2.1

“Party A shall have a **preemptive right** to carry out mobile game services with Party B on a nationwide basis.”

约定“优先权”

研究摘要 · 记录节选

“**functionally analogous** to a right of first offer/negotiation”

“**No explicit** 'right of first refusal', 'right of first offer', or 'right of first negotiation' terminology appears …”

“… should be **reviewed by a lawyer**.”

最终报告 · 原句摘录

“2.1 Party A shall have a **preemptive right** to carry out mobile game services with Party B on a nationwide basis.”

可审阅的对象包含原始条款，也包含处理中新增的解释

英文均来自已有记录，省略处以 … 标记。任务要求摘录原文，未将最终报告省略解释判为错误。

实际上下文：后续调用只看到部分材料

同一任务中的调用，可见范围并不相同

实际请求内容	研究者调用 4	报告者调用 7
合同原文	13 个片段	1 个片段（含 §2.1）
研究摘要	本次生成的目标	出现在实际输入中
请求长度	22,209 字符 / 5,041 tokens	5,279 字符 / 1,203 tokens

12 个原文片段没有直接进入报告者请求。
第 2.1 条**同时**出现在原文片段与传入摘要中。

数据来自实际请求抽取记录；token 数使用分析模型 tokenizer。可见性只能确认“能看到”，不能确认“用了”。

研究定位：内容关系与调用记录的结合

围绕同一句输出，保留不同层次的依据

信息层次	在合同例子中能查看什么	MemoryFlow 的连接对象
最终引用	报告原句对应合同 §2.1	原文位置与具体输出
调用记录	研究者和报告者各自看到什么	调用身份与可见范围
局部来源关联	摘要或报告与哪些输入更相关	输出片段 × 可见来源
跨调用内容关系	**“功能上类似”的解释在哪里出现**	**中间表述及其上下游**

研究目标：使具体表述能回到原文、中间解释和所属调用

互补能力的分工示意：组内生成时引用研究提供局部来源信号基础。

两个挑战与整体方法

实际困难	方法设计	当前证据
一次调用：长材料、多个目标 来源如何对应已有输出？	方法一：冻结模型回放 局部矩阵 + 前缀复用	47 个目标的来源评测 88 个目标的效率实验
多次调用：可见范围不同 摘要改写后如何接回原文？	方法二：核对实际传递 连接前后局部矩阵	合同两跳案例 内容身份与查询原型



局部关联与内容传递共同组成可回查路径

方法一：回放已有输出，建立局部矩阵

输入与输出已经记录，分析阶段读取来源关联

输入：研究者实际可见材料

13 个合同片段
其中 S_1 含第 2.1 条优先权约定

目标：已经生成的整段摘要 U

引用条款，并解释与所查类别的关系

冻结 Qwen2.5-7B-Instruct
回放并读取目标与来源的注意力关联

摘要 U 的候选来源	关联分数	排序
S_1：片段 2593:3850	0.7569	1
S_2：片段 31192:32479	0.1692	2
其余 11 个片段	合计 0.0739	3 - 13

矩阵每一行对应输出，每一列对应来源
右侧是摘要 U 这一行转成的排序表

固定头 (19,15)，分数用于关联排序。整段摘要分数不等于句级分数，也不是执行模型的因果责任。

方法一：复用相同长前缀的计算

逐目标重算

共同提示与材料 P → 目标 T1

共同提示与材料 P → 目标 T2

共同提示与材料 P → 目标 T3

长材料重复读取三次

相同前缀复用



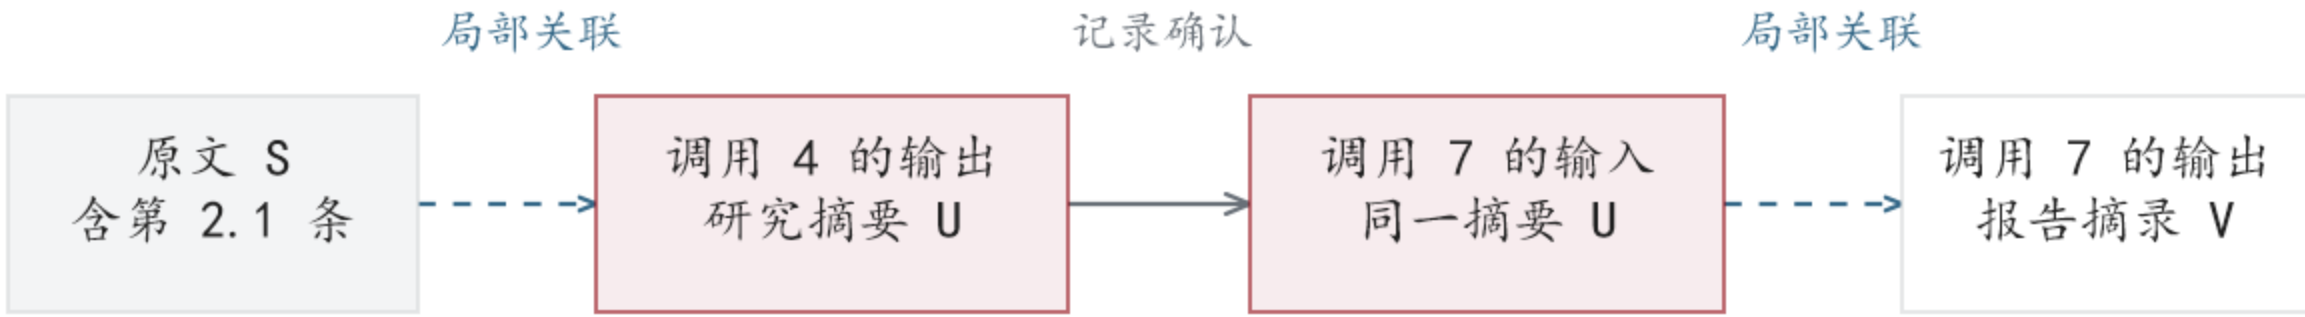
共同部分一次，各目标依次处理

实测批次：88 个目标，36 个前缀组，64.26% 的前缀 token 可复用

复用要求 token、位置和可见关系完全一致。当前实现依次处理分支，未做多分支一次前向打包。

方法二：用实际传递的内容连接调用

接点是实际传入的同一份内容



连接时核对	本例处理
是否真的传入后续请求？	摘要全文在报告者实际输入中出现
文本相同是否就是同一输出？	原文出现、摘要引用、最终生成分别保留身份
后续还能直接看到原文吗？	能，保留 §2.1 直达路径，与摘要路径并存

固定案例已经核对传递关系；新的改写需建立新单元，通用上下文分支与文件版本尚待完善。

方法二：查询结果保留证据类型与位置

查询对象：最终报告中的第 2.1 条摘录

保留哪些信息

内容：报告里的这句原文
位置：report_span_0
生成：报告者调用 7
来源：原文与中间摘要
关系：记录确认 / 回放估计

现有查询输出 • 可读整理

```
report_span_0
  [记录] 生成归属：call7
  [记录] 原文可见：2593:3850
  [回放] 摘要 summary_final：0.6437
  [回放] 原文 2593:3850：0.3563

继续查看 summary_final
  [记录] 摘要生成调用
  [回放] 原文候选及关联分数
```

同文输入与本次输出分开记录，
避免把文字重复误当成生成关系

由已存查询结果整理。当前尚未自动递归遍历所有回放关联边；句级查询仍提示“句级分数未回放”。

评价设计：一条陈述需要一套完整证据

GenMem：评价能否找齐一条陈述所需的证据

实际标注例 • case_02 T03（开发集，中文转述）

> Secret Symphony 是 Katie Melua 的
> 第五张录音室专辑，并由 Mike Batt 参与制作。

event 33 中的证据	支持目标的哪个部分
一条结果：专辑序号信息	第五张录音室专辑
另一条结果：制作信息	Mike Batt 参与制作

共同找到才算完整

主评测口径

47 个评测目标
8 条评测轨迹
8 个开发目标另列

完整证据 @K

前 K 个候选联合覆盖
至少一套完整证据

原窗口候选 + contextual64_v4 规范证据。组内必要片段全部覆盖，组间允许替代；未标候选不当负例。

来源质量：前十候选找齐 33 / 47 个目标

统一候选与证据标准，主评测 N = 47

方法	完整证据 @5	完整证据 @10	首位片段命中
固定头回放（当前配置）	61.70%	70.21%	48.94%
D-Full（迁移关系头）	53.19%	68.09%	34.04%
BM25（词面检索）	55.32%	61.70%	57.45%
最后 8 层全头平均	57.45%	61.70%	34.04%

完整证据：固定头前十找齐 33 个，BM25 为 29 个

BM25 更容易首位命中一个片段，当前回放更有利于把整套证据放进前十。
抽样头 L21H5 的 @10 为 74.47%，因此尚不能断言当前固定头最优。

修复后结果，标签与评价分母不变。小样本初步证据，不作统计显著或所有指标领先结论。

个例分析：找到部分材料仍可能缺关键证据

同一轨迹的两个已记录个例：前十找齐与前十未找齐

已确认的现象	样例 A · selected_05	样例 B · selected_09
规范证据结构	3 套替代证据 / 共 9 个片段	1 套证据 / 3 个片段
前十完整覆盖	成功覆盖至少一套	未覆盖完整一套

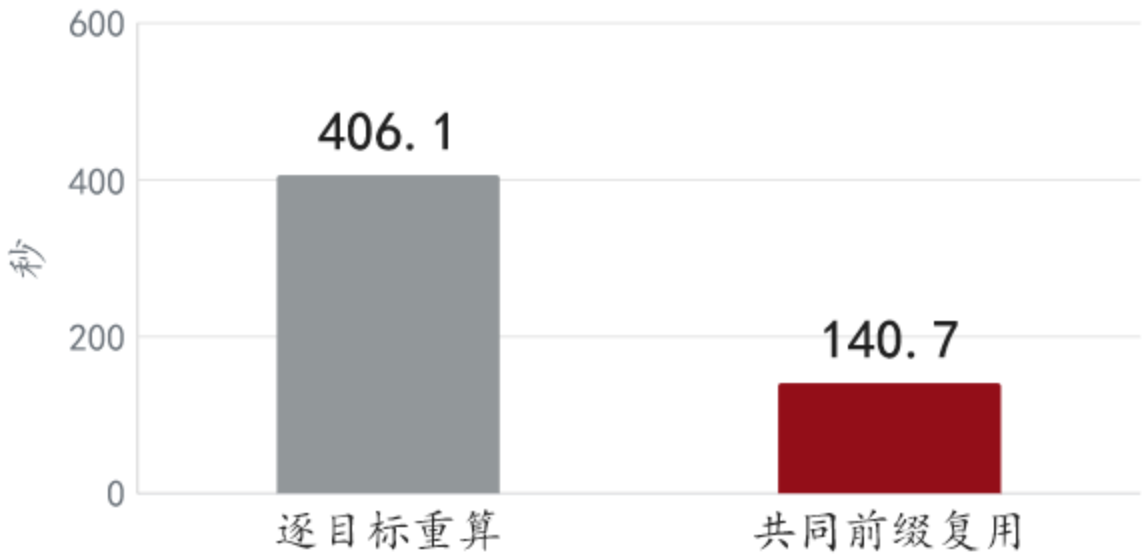
待补原文与排序：把判分解释成可核对的原因

对照材料	补齐后需要直接看见
目标与证据原句	目标包含哪些条件，各必要片段分别支持什么
固定头 / BM25 前十	已找到的片段与缺失片段，准确排名及来源位置

G1 待补。样例来自同一评测轨迹；此处为已确认的判分现象，目标原文与修复后排序证据待补。

计算效率：整批回放加速 2.89 倍

88 个目标 / 36 个前缀组，同模型、同输入、同评分



三遍耗时（秒）	重算	复用
1	536.87	140.72
2	405.40	140.94
3	406.09	140.61

中位加速 2.89×

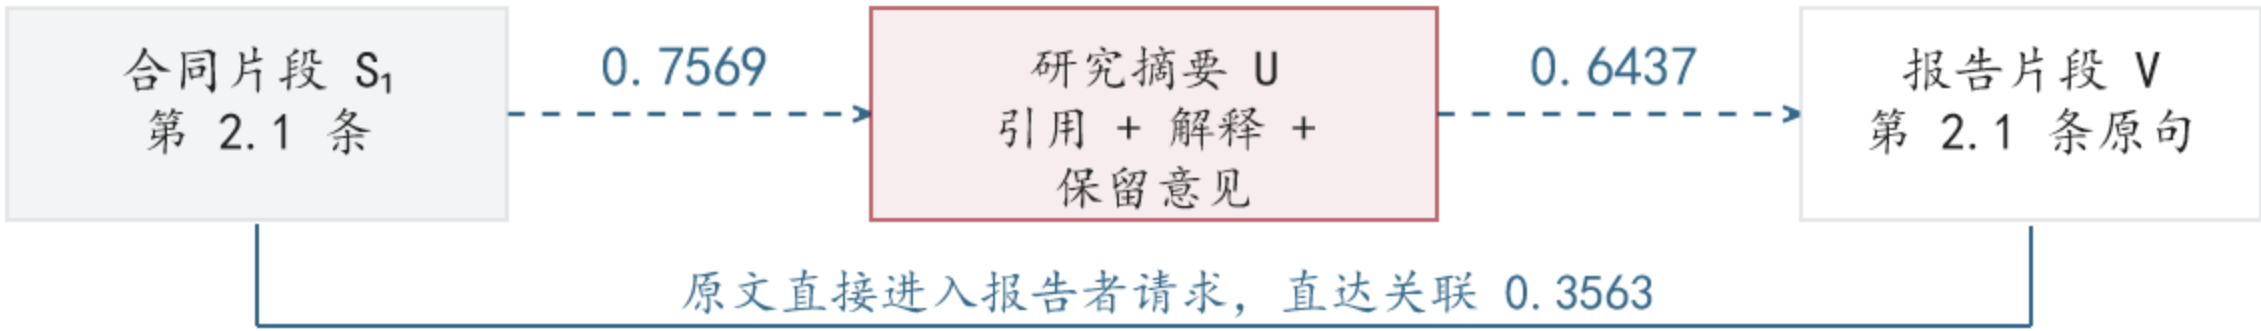
逐候选分数完全一致
峰值显存均为 32.82 GiB

减少共同材料的重复计算，评分结果保持不变

正式三遍均保留。只计回放主体，加载、预处理与预热另列；共享 GPU，不等于整个 Agent 的加速。

合同链路：摘要与原文形成两条候选路径

可从报告摘录进入摘要，也可直接回到合同原文



局部分析对象	实际候选	可核对的结果
整段研究摘要 U	13 个原文片段	S_1 排名第 1，次名为 0.1692
最终报告片段 V	摘要 U + 原文 S_1	摘要 0.6437，原文 0.3563

蓝线表达回放关联。内容传递已核对；两条候选路径并存，尚不能唯一确定原模型实际使用哪条路径。

链路回查增加了哪些可审阅内容

同一条最终摘录，对应两种审阅范围

直接回查原文

§2.1 “… preemptive right …”

能核对：报告中的原句是否来自合同，以及具体条款位置。

沿中间摘要继续回查

“functionally analogous …”
“No explicit … terminology appears …”
“… should be reviewed by a lawyer.”

多看到：类别解释、术语不对应的说明、复核建议及其产生环节。

已有证据：中间内容提供了最终引用之外的解释与保留意见

尚未测量是否提高找错率或减少审阅时间；本例也没有证明直接检索会出错。

正式 DCCv2 案例：一项判断的依据链

展示单元：NBA RuleArena 中一个具体操作的合规判断

待补：完整 DCCv2 运行与真实内容

题面与规则	中间核查	最终判断
题面事实与假设原句 适用规则及条件原句 各自来源位置	Agent 如何解释规则 如何代入题面条件 相关请求与输出片段	实际判断及一句核心理由 采用的事实与规则 保留意见或冲突

同一目标的对照

只看最终引用：能核对哪些依据？
加入中间路径：能否定位解释、条件变化或冲突发生的位置？

G2 待补：完整运行记录、判断原句与来源材料。DCCv2 适配由协作方推进。

下一步实验：中间路径是否帮助定位变化

待验证：中间路径是否帮助找到内容变化发生的位置

待选自然案例或受控例子	需要保留的对照	检查什么
条件省略	规则原文有限制条件 摘要或结论未保留	能否指出首次省略位置
错误沿用	中间摘要出现可核对错误 后续继续使用	能否追到错误出现环节
纠正未传递	后续材料提供纠正信息 最终表述仍沿用旧内容	能否定位纠正没有接上的环节

比较对象：直接检索 / 只有调用记录 / 内容链路回查

记录原始依据是否找齐、变化位置是否定位正确，以及需审阅的片段数。

G3 计划实验。优先使用自然记录，受控修改单独标注；当前尚未形成对照结果。

当前进展与证据边界

工作层次	当前进展	仍需补充
局部来源分析	47 个评测目标 完整证据前十找齐 33 个	具体成败样例的原文排序对照
计算复用	88 目标、三遍测量 2.89×，逐候选分数一致	不同工作负载下的适用范围
跨调用连接	真实合同链路 生成归属、可见性和局部查询	通用遍历、分支与版本组织
正式场景与效用	DCCv2 案例展示已规划	完整运行与内容变化对照

局部模块已有实证，跨调用已有原型，整体效用仍需针对性验证

总结

研究价值	让审阅者查看具体内容的依据，以及中间解释和改写
当前进展	局部来源排序、前缀复用已有实验 合同例子已连接原文、摘要与报告
下一步重点	完整 DCCv2 案例 中间路径对定位内容变化的额外价值

北京大学
PEKING UNIVERSITY

讨论

敬请老师批评指正

MemoryFlow

备选：完整方法对照与头选择

方法	完整组 @5	完整组 @10	首位片段命中
固定头回放	61.70%	70.21%	48.94%
D-Full（3 种子）	53.19%	68.09%	34.04%
BM25	55.32%	61.70%	57.45%
平均头	57.45%	61.70%	34.04%
R-SYM（3 种子）	44.68%	58.16%	39.01%
Qwen 表示相似度	27.66%	40.43%	19.15%
CLM 官方头迁移	12.77%	19.15%	12.77%
均匀随机排序	1.08%	2.15%	0.44%

抽样头 L21H5：完整组 @10 = 74.47%，高于当前固定头

修复后主评测 N=47。不据主评测重新选头；CLM 未在本任务训练，不能推广为方法整体优劣。

备选：回放位置与分数含义

目标文本已知，因果可见性仍然保持

目标 token	a	b	c
读取预测位置	前缀最后位置	a 所在位置	b 所在位置
可见目标前文	无	a	a、b

读出：来源区间求和，目标位置取平均，再在候选间归一化

输入 prompt + target[:-1]，读取位置 P-1 … P+n-2。
GenMem 固定候选提示与实际调用回放，分别报告协议。

CUAD 抽取记录仍有完整输出前文缺口；来源关联不等于事实正确性、生成概率或因果责任。

备选：计算安排与计时范围

安排	目标处理	共同前缀	目标之间
A	逐 token	逐目标重算	依次
B	成块	逐目标重算	依次
C	成块	普通批处理仍重复	普通 batch
D（当前）	成块	同组只计算一次	依次、复位缓存

88 目标 / 36 组，其中 24 个单目标组无法组内复用

预处理 29.5 s，预热 30.5 s 另列，模型加载未单独计时

三个高度共享小组为 6.7–7.6×，整批中位为 2.89×。不相加或相乘；多分支 packing 尚未实现。

备选：生成时提取与独立回放

单条短样例，同一生成服务；两条路线使用不同模型

路线	稳态耗时	说明
只生成 S	3.687 s	正式 2 次，预热另列
生成 + 同模型来源提取	4.097 s	额外 0.410 s，正式 3 次
生成后 + 独立 7B 回放	4.701 s	回放 1.014 s，仅 1 次

此短条件下，生成时提取更快

独立回放面向已有输出或无法读取执行端内部信号的情形。

输入 3,162 tokens，输出上限 128；生成 27B FP8、回放 7B。加载 9.179 s 另列，非同骨干算法比较。

备选：跨调用边界与路径计分

问题	当前做法与边界
记录与关联	可见性、内容身份由记录确认；来源强弱由回放估计
路径计分	间接乘积 0.4872，直达 0.3563；均为候选关联
文本粒度	整段摘要有分数，拆出的句子尚无独立回放分数
记录完整性	CUAD repair 完整输出未保存，输出前文仍有缺口
通用实现	递归遍历、上下文分支、文件版本仍需完善

一个中间摘要不足以验证路径聚合的优劣

退化的 NBA v6 回放不作为有效结果；路径分数不解释为依赖概率，也不相加成置信度。