# MemoryFlow

## 面向 Agent 多步任务的细粒度信息流溯源

研究进展汇报

2026 年 11 月

# Agent 的判断，需要能回到依据

## DCC：基于文档与规则的核查

**真实输出 · DCCv2 NBA**

> “Answer: True.
> Illegal Operation: A.
> Problematic Team: B.”

哪一条规则支持这个判断?
哪一步形成了这条解释?

## 报告引用核查

**会议场景 · 应用说明**

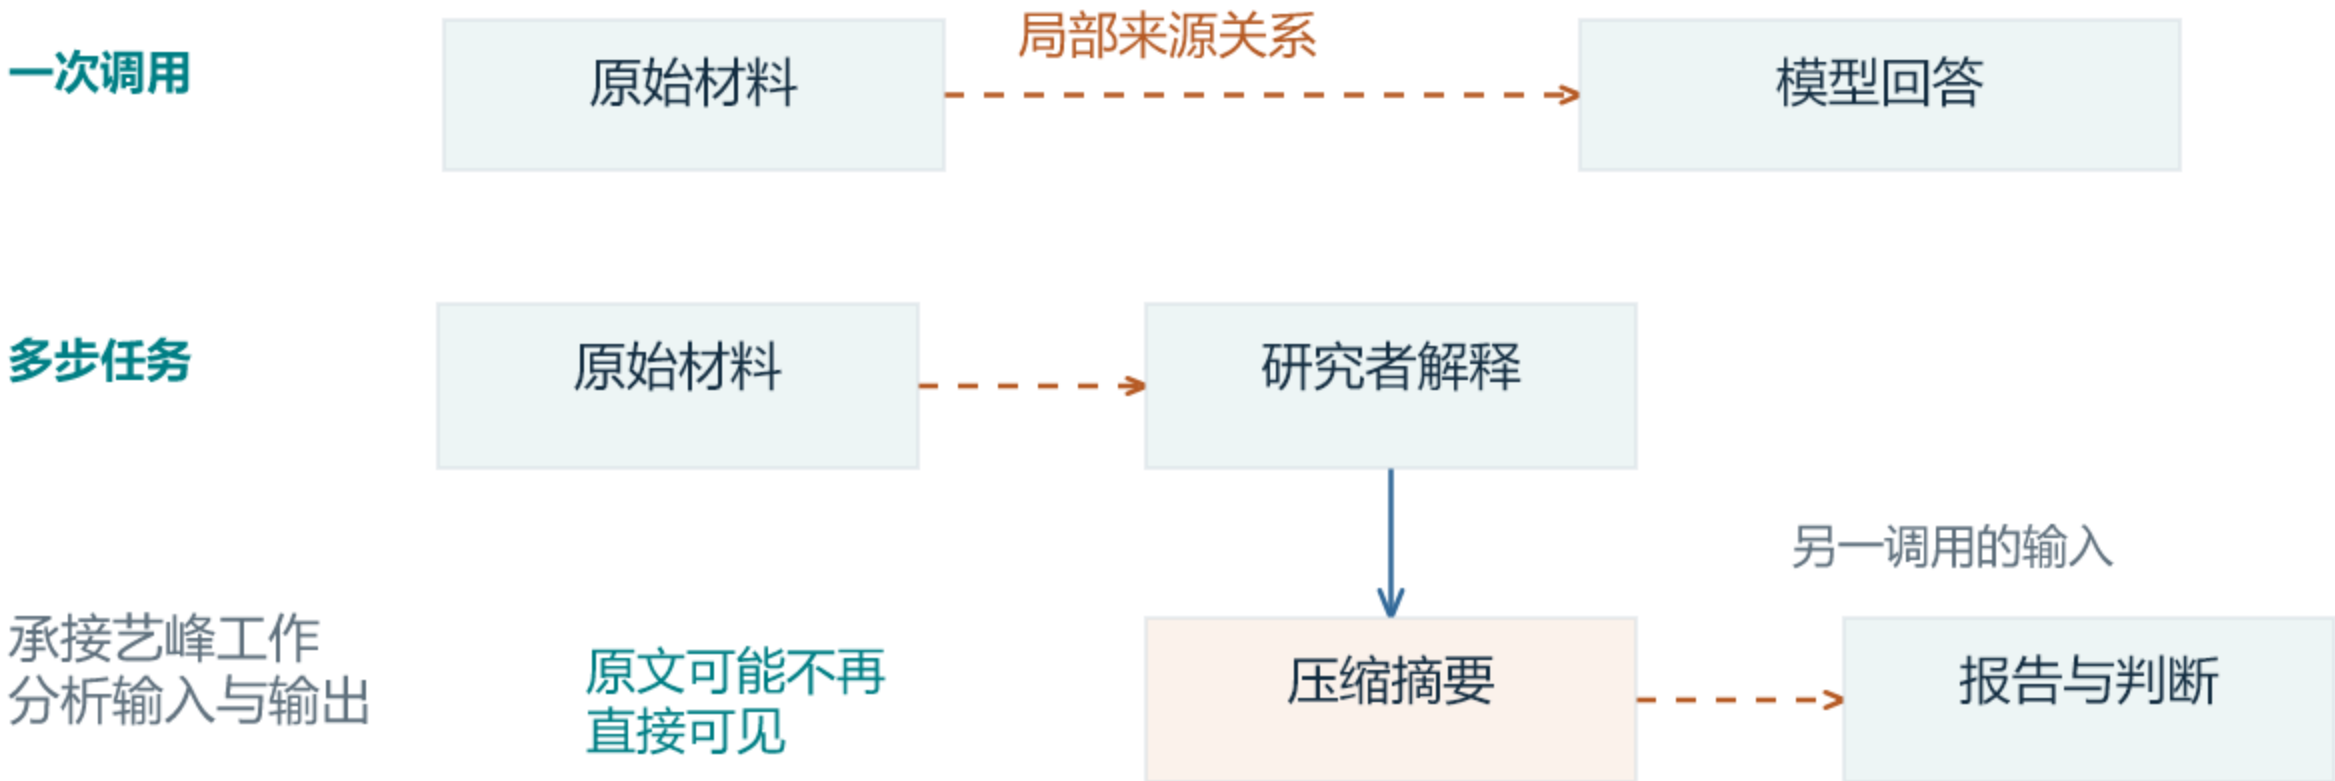
> “**9899 万**农村贫困人口全部脱贫，**832 个**贫困县全部摘帽”

数字出自哪段材料?
摘要、改写后还能核对吗?

**我们需要核查具体内容，以及内容经过的处理过程**

左：单题实际运行输出，答案错误。右：会议材料中的场景说明，未作为本轮实测。

# 多步 Agent 扩大了来源分析的对象




新增对象：中间解释、内容传递与上下文变化。执行模型与独立分析器可以分开。

# 跨步骤、可核查的来源链

## 如何在复杂 Agent 系统中，以可接受的额外开销，构建跨步骤、可核查的来源链？

### 原始材料

定位到可阅读的证据

### 中间加工

保留摘要与解释

### 核查边界

说明记录、估计与断点

# 一条合同条款，在处理中增加了解释

**合同原文 • §2.1**

"Party A shall have a **preemptive right** to carry out mobile game services with Party B on a nationwide basis."

看见 13 个原文片段

**研究者摘要 • call4**

**功能上近似** first offer / negotiation

"No explicit … terminology appears in the contract."

建议律师复核

**报告原句 • call7**

"2.1 Party A shall have a **preemptive right** to carry out mobile game services with Party B on a nationwide basis."

看见摘要 + 含 §2.1 的原文片段

## 最终引用之外，中间解释也值得被核查

旧 CUAD 真实机制例。摘要中文为转述，英文省略用 … 标注。原文也直达最终调用。

# 不同应用，共享内容传递的结构

**DCC · 真实记录**

规则与事实 → 模型解释 → A / B 判断

解释依据在哪里?

**报告 · 应用说明**

9899 万 / 832 个 → 数字摘要 → 文字引用

改写后能否回到出处?

**变化追查 · 概念示意**

带条件 C → 条件 C 未保留 → 后续沿用

哪一步改变了条件?

当前实证集中在局部来源分析与 DCC 机制案例，应用示意不计为已完成实验。

# 两项挑战：每一步怎么算，各步怎样接

## C1 高效构建局部来源关系

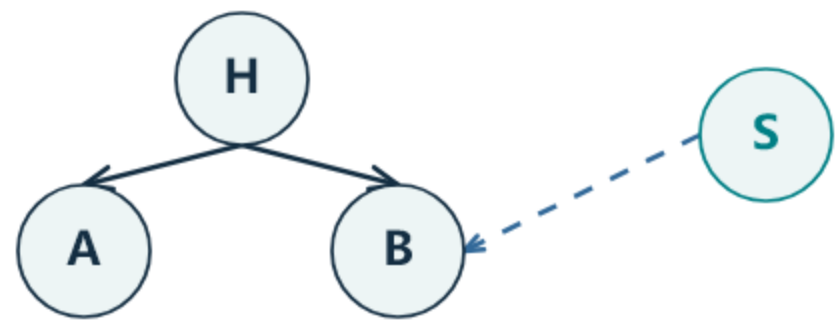
长材料重复读取
目标与调用不断累积

**方法一：局部回放与前缀复用**

## C2 复杂 Harness 的跨调用连接

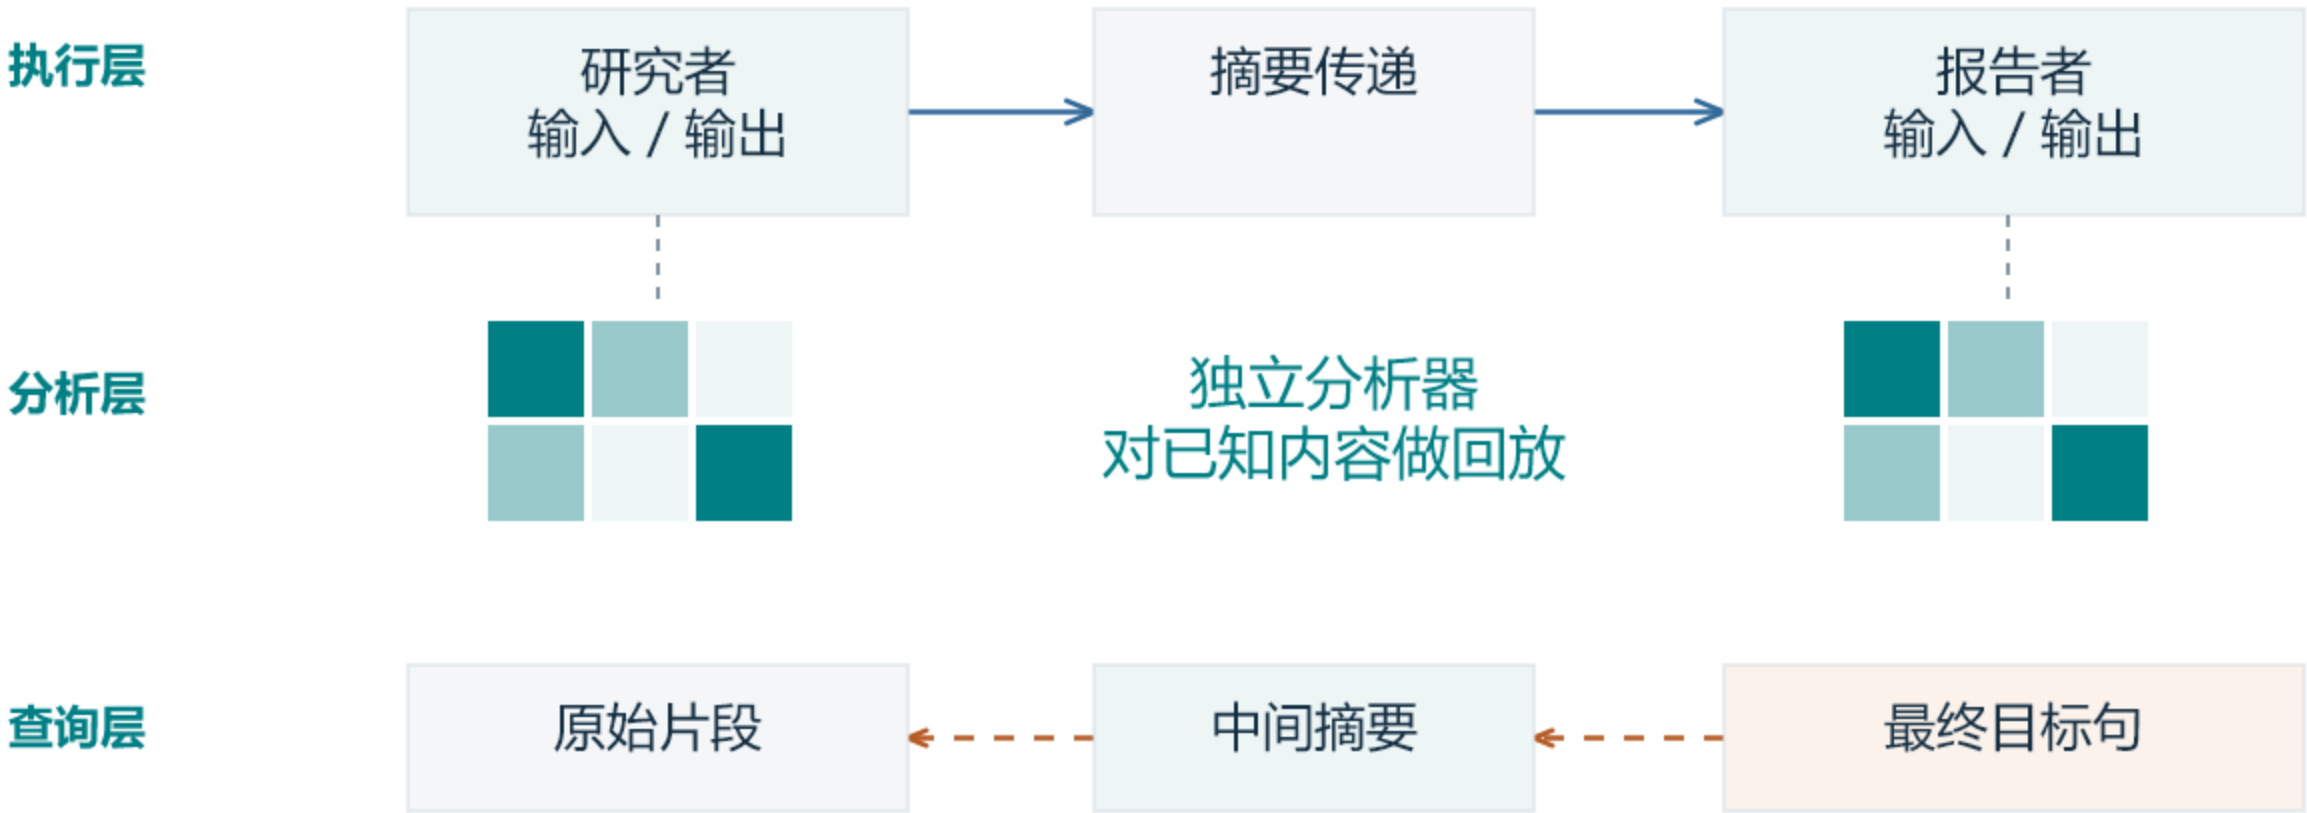
摘要压缩、独立子会话
上下文分支与文件版本

**方法二：会话森林与内容连接**




Harness：安排模型、工具与记忆协作的执行框架。图为挑战示意，两个方法分别处理计算与结构。

# MemoryFlow：局部关系与实际传递协同




概念示意。执行记录确认传递，回放分数估计局部关联。承接艺峰来源信号与 Harness-RL 会话组织。

# 方法一：对已知输出进行局部来源回放

### 已保存的实际输入

13 个合同片段
其中一个片段包含 §2.1

### 已生成的目标内容

研究摘要 U
原句引用、功能类比与复核提醒

### 摘要 U 的真实局部来源排序

| 候选来源 | 关联分数 |
| --- | --- |
| 含 §2.1 的片段 | 0.7569 |
| 次名片段 | 0.1692 |
| 其余 11 个合计 | 0.0739 |

输出目标 × 可见来源
构成可查询的局部矩阵

旧 CUAD 整段摘要示例；固定 7B 分析器。保持真实前文与因果可见范围，不读取目标之后的输出。

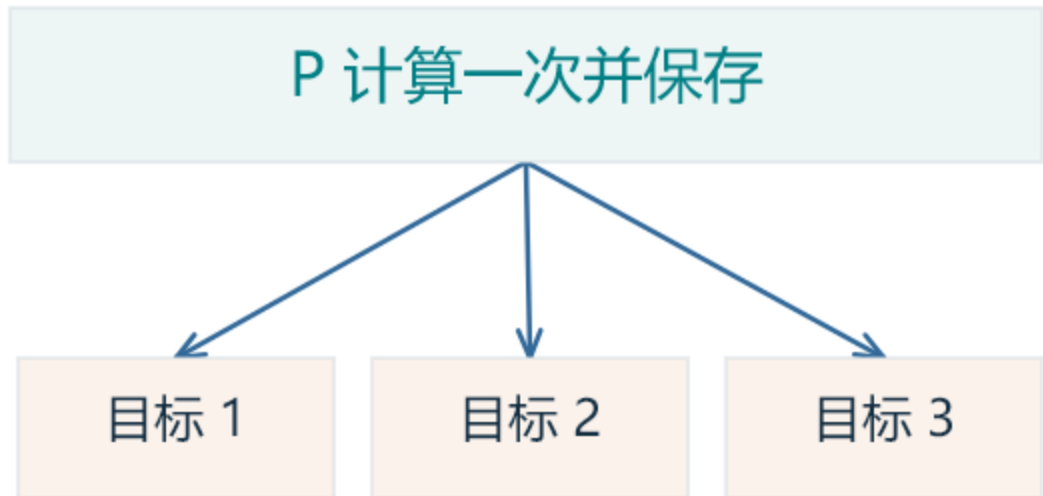
# 方法一：相同前缀只计算一次

### 逐目标重算

| | |
|---|---|
| 相同提示与材料 P | 目标 1 |
| 相同提示与材料 P | 目标 2 |
| 相同提示与材料 P | 目标 3 |

同一份长输入，重复三次

### 共享前缀，目标依次分析



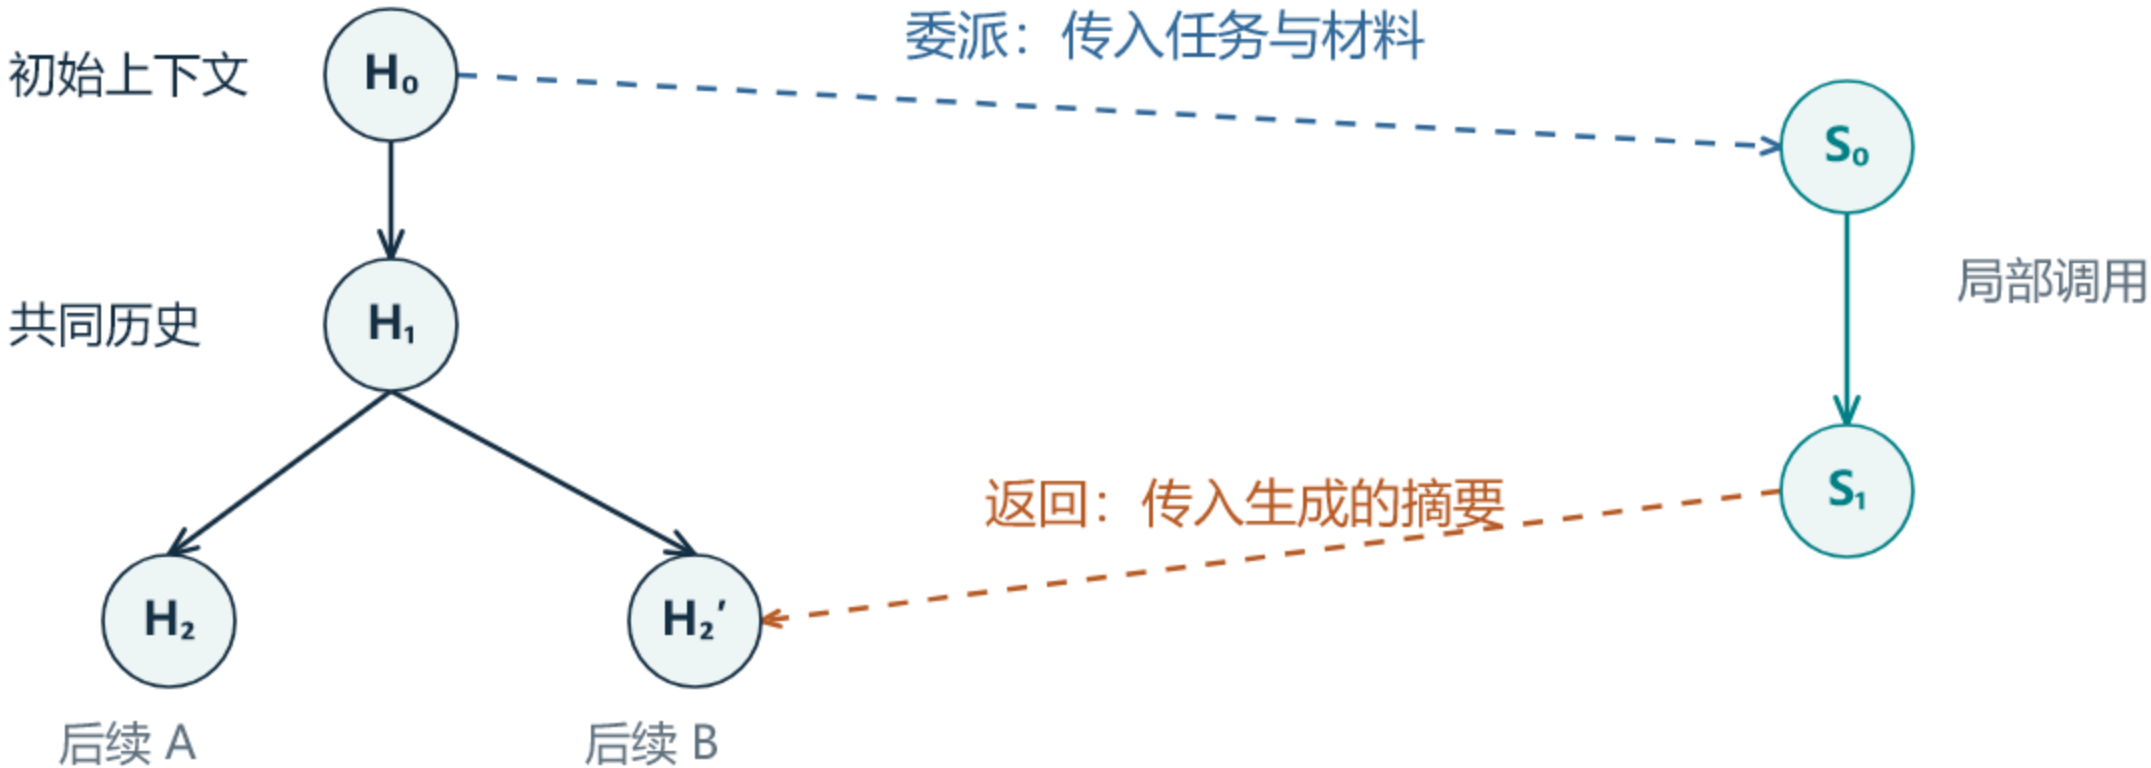

共同部分复用，分支仍串行

复用条件：token、位置、可见范围完全一致。多分支 packing 属于后续探索，当前不计入收益。

# 方法二：会话历史组成一片森林

**主会话：共享历史之后可以分支**

**子会话：独立维护自己的历史**




概念示意，参考 Harness-RL §3.3。实线树枝表达会话延续，跨树虚线表达委派 / 返回。

# 方法二：局部关联接上实际内容传递

**子会话中的一次调用**

**主会话中的一次调用**

回放估计　　记录确认　　回放估计

原文片段 S　- - - ->　生成摘要 U　——>　输入摘要 U　- - - ->　最终句 V







列：原文片段　行：摘要内容

列：可见输入　行：最终内容

**查询从最终句向前展开；缺失的连接保留断点**

概念示意，不填实测分数。蓝色实线确认传递，橙色虚线表示关联估计；图的箭头方向是内容形成 / 传递。

# 三层证据，分别回答三个问题

| 验证层次 | 要回答的问题 | 当前证据 |
| --- | --- | --- |
| 局部来源质量 | 必要依据能否找齐? | 47 个评测目标<br>8 条评测轨迹 |
| 计算成本 | 重复计算能省多少? | 88 个目标 / 36 前缀组<br>另有小模型探索 |
| 正式任务案例 | 具体判断能否跨步核查? | DCCv2 单题完整运行<br>正式路径与在线成本待补 |

## 局部质量、计算收益和任务正确性分别报告

主分析器为冻结 7B。开发 / 评测分开，批量效率与来源质量使用各自的目标集合。

# 指标：找齐一组必要依据

## 目标陈述需要完整依据

**可替代的充分证据组**

A + B　或　C + D

| 前 K 个来源里找到了什么 | 是否命中 | 原因 |
| --- | --- | --- |
| A | 否 | 缺少 B |
| A、C | 否 | 两组都未完整 |
| A、B | 是 | 完整覆盖第一组 |
| C、D | 是 | 完整覆盖第二组 |

判分概念示意。来源覆盖衡量依据查找，不等于最终答案正确率。

# 47 个目标中，前十来源找齐 33 个

**33 / 47**

CompleteGroup@10
前十推荐找齐一整组必要证据

8 条评测轨迹
固定头、原窗口候选协议

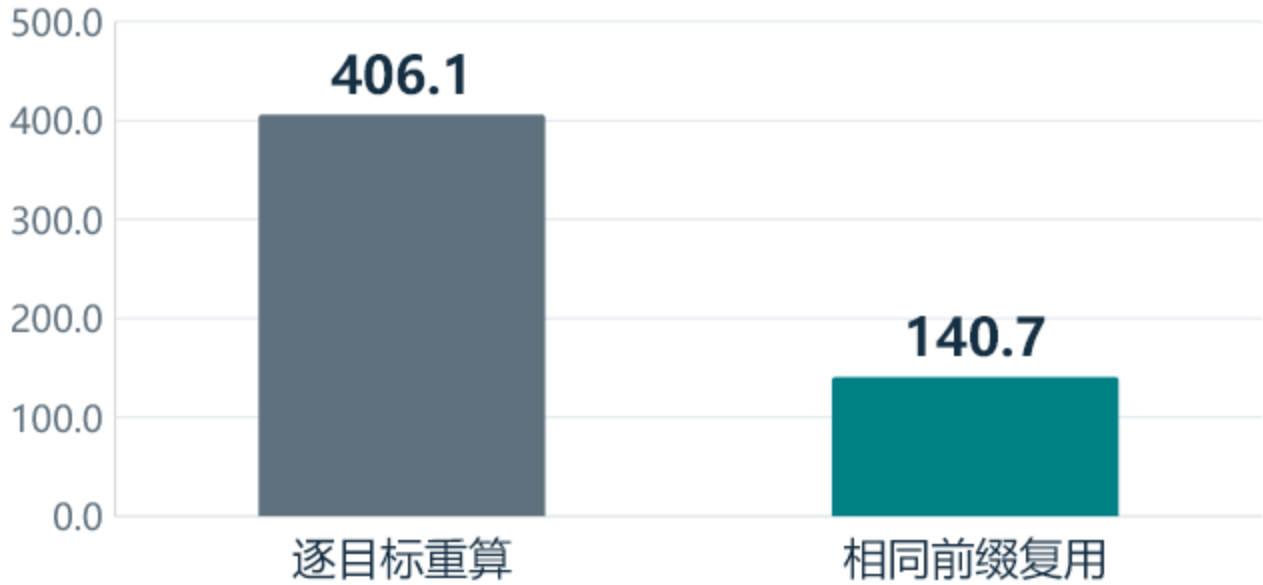
| 代表方法 | @5 | @10 | 首位片段 |
|---|---|---|---|
| 固定头回放 | 61.70 | 70.21 | 48.94 |
| BM25 | 55.32 | 61.70 | 57.45 |
| D-Full-64 | 53.19 | 68.09 | 34.04 |
| 平均头 | 57.45 | 61.70 | 34.04 |

**完整组与首位命中，体现不同取舍**

表中单位为 %。N = 47。不把来源覆盖率称为答案准确率；完整对照与头敏感性见备选。

# 分数一致，整批回放耗时降至约三分之一

**整批回放主体耗时 / 秒**




**2.89×**

中位加速

88 个目标，36 个前缀组
64.26% 前缀 token 可复用

**三轮逐候选分数一致**

三轮中位数；共享 GPU；不含 CPU 预处理 / 预热 / 未单独记录的加载。收益仅对应回放计算。

# 更小的分析器，带来成本与质量取舍

| 分析器 | 前十找齐 | 回放时间 / 秒 | 峰值显存 / GiB |
| --- | --- | --- | --- |
| 7B | 33 / 47 | 105.43 | 32.82 |
| 1.5B | 30 / 47 | 46.54 | 11.05 |

**少找齐 3 个目标**

**约 1/3 峰值显存**

**资源成本下降，主案例保留 7B**

探索性结果：时间为单次，开发集选头条件不同。不能视为纯参数量消融或稳定吞吐比较。

# 正式 DCCv2 运行完成，但判断有误

## 任务与交付中的事实

| 条目 | 金额 / 美元 |
| --- | --- |
| 2024—25 Salary Cap | 140,588,000 |
| Team B salary | 136,000,000 |
| 模型算出的 cap room | 4,588,000 |
| Operation A | 7,000,000 |
| Operation B | 4,000,000 |

## 实际结论

> True / A / B

## 官方标签

> True / B / B

24 次调用，8 轮，571.9 秒
正式交付存在，单题结果 0 / 1

DCCv2 正式单条运行。216 是任务总量，不是评测样本数；本页金额与解释来自实际任务 / 交付。

# 错误判断之前，出现了怎样的规则解释

### call10 • 关键规则解释

> “Since Team B is under the Salary Cap … Team B **must use its cap room** to sign free agents, not a salary cap exception.”

### call22 • 最终操作判断

> “Operation B ($4,000,000) is within Team B’ s $4,588,000 cap room **and complies**.”

支持解释的具体原文
当前尚未定位，待核查

中间摘要 / 前版产物
关联路径待校准




父版本关系已记录

## 核查对象已具体到句，正式跨步链路仍待补证

P01 待补。关键解释属于模型输出，不作为权威规则；尚未证明“无依据”或确定唯一出错步骤。

# 来源齐备，会让用户多等多久




P02 待测。时间线为结构示意、非比例；同时报告答案时刻、来源齐备时刻、分析范围和 GPU 资源。

# 已具备局部实证，正在补齐系统级证据

| 层次 | 已经得到什么 | 下一步补什么 |
| --- | --- | --- |
| 局部方法 | 47 目标来源质量<br>前缀复用 2.89×<br>小模型成本 / 质量取舍 | 维持协议与结果身份<br>不据评测重新挑头 |
| 跨调用原型 | 旧 CUAD 可查询机制链<br>DCCv2 完整真实运行 | 核准正式路径<br>确认具体上游来源 |
| 系统级验证 | 记录、读出与查询基础 | 测完整任务额外等待<br>检验跨步核查的实际用途 |

## 优先补齐“正式来源链”和“完整任务成本”

来源关联辅助核查；真实性、因果影响与广泛任务效果仍需独立验证。packing 正确性属于补充探索。

# 让重要判断留下可回查的来路

**一句最终判断，**
**值得被展开成一条可核查的来源链。**

**局部来源信号已有实证**

**计算复用已减少分析成本**

正式跨步路径与任务级效用，是下一阶段重点

# 完整质量表与头敏感性

| 方法 | CompleteGroup@5 | CompleteGroup@10 | FragHit@1 |
|---|---|---|---|
| 固定头回放 | 61.70 | 70.21 | 48.94 |
| BM25 | 55.32 | 61.70 | 57.45 |
| 平均头 | 57.45 | 61.70 | 34.04 |
| D-Full-64 | 53.19 | 68.09 | 34.04 |
| R-SYM | 44.68 | 58.16 | 39.01 |
| Qwen F_mean | 27.66 | 40.43 | 19.15 |
| CLM | 12.77 | 19.15 | 12.77 |
| 随机 | 1.08 | 2.15 | 0.44 |

探索头 L21H5：@10 = 74.47%；评测集不用于重选主配置

单位 %，47 个评测目标。固定头为零基 layer 19 / head 15；探索头结果仅用于敏感性说明。

# 局部矩阵的计算口径

## 固定分析器：Qwen2.5-7B-Instruct

固定读出位置：零基 layer 19 / head 15

| 对象 | 计算与核对 |
| --- | --- |
| 候选来源片段 | 对片段内 token 的关联质量求和 |
| 目标输出片段 | 对目标位置平均，保留真实前文 |
| 可见范围 | 遵守因果可见范围，排除未来输出 |
| 归一化 | 候选内归一化与原始质量分开记录 |

候选集合改变后，不直接横比归一化数值。模型关联估计不等于执行模型真实依赖概率。

# 短条件下，独立回放仍有额外成本

| 路线 | 时间 / 秒 | 测量条件 |
| --- | --- | --- |
| S：正常生成 | 3.687 | 正式 2 次 |
| S+O：生成时捕获 | 4.097 | 正式 3 次，同输出 |
| S+R：生成后串行回放 | 4.701 | S 中位数 + R 单次 1.014 |

## 短条件中，串行回放稍慢

5 个目标 / 104 个来源；27B FP8 生成与 7B 回放，模型未共驻。不能外推完整任务在线表现。

# 旧 CUAD：两条路径并存




记录确认：原文也进入报告者请求

该候选的回放关联：0.3563

**原型乘积 0.4872，不作依赖概率解释**

旧系统真实机制例。两条候选路径共存，尚不能唯一确定执行模型实际使用哪条。

# 实现边界与证据更新位置

| 问题 | 通过条件 | 影响页面 |
| --- | --- | --- |
| 长输入局部读出 | 因果可见范围、分母与候选分类核准 | 正式案例第 19 页 |
| 跨调用生成归属 | 目标、摘要、版本与原始调用映射一致 | 正式案例第 19 页 |
| 任务级在线成本 | 真实重叠执行，记录答案与来源完成时刻 | 成本第 20 页 |
| 多分支 packing | 隔离计算与基准逐候选分数一致 | 补充优化，不阻塞正文 |

## 当前材料依据：2026-11-01 核准资料包

未经核准的长文本新百分比不进入正文。来源路径的效用与因果解释需要后续独立验证。